SOFTWARE ENGINEERING LAB | LAB 22

N+1 Query Problem

Batching Relasi Data untuk Eliminasi Latensi Tersembunyi

Lukman / lukman-ss • github.com/lukman-ss/software-engineering-lab

N+1 Query Problem: Anti-Pattern Latensi Tersembunyi

Satu query untuk mengambil koleksi, lalu N query terpisah untuk setiap item

MOTIVASI

- N+1 adalah masalah 'invisible until it hurts' — berfungsi sempurna pada data uji kecil
- Setiap query individu terlihat cepat (<1ms), sehingga lolos dari slow query logs
- Degradasi performa akumuler: request yang harus 200ms justru butuh 2.4 detik di produksi

KONSEP

- Anti-pattern N+1: 1 query induk + N query anak per item
- Kompleksitas menjadi O(N) relatif terhadap jumlah record
- Sering terjadi di ORM lazy loading default dan GraphQL resolvers

STUDI KASUS

- GET /api/work-orders: 100 work order, 5 item tiapnya =
- : 101 query (1 + 100) vs 2 query (batching)
- Pada data uji 5 work order: hanya 6 query — tidak terlihat masalahnya

N+1 is invisible until it hurts. Batch related queries, don't loop them.

Anatomi N+1: 1 + N = N+1

Loop-driven retrieval memicu eksekusi query berulang di dalam iterasi

ALUR EKSEKUSI N+1

- Query #1: GetAllAuthors() → mengembalikan 3 author
- Loop iterasi ke-1: GetPostsByAuthorID(1) → Query #2
- Loop iterasi ke-2: GetPostsByAuthorID(2) → Query #3
- Loop iterasi ke-3: GetPostsByAuthorID(3) → Query #4
- Total: 4 query (1 + N di mana N=3)

KODE ANTI-PATTERN

- authors := store.GetAllAuthors()
- for _, author := range authors {
- posts := store.GetPostsByAuthorID(author.ID)
- }

SKALA NYATA

- Jika N=1000 author, query count = 1001
- Jika N=10000 author, query count = 10001
- Linear scaling dengan jumlah record — tidak berkelakuan baik

Each item in a loop triggers its own query — batch before you iterate.

Titik Buta: Slow Query Log Gagal Mendeteksi

Query individu terlihat sempurna, tapi akumulasi menyebabkan bottleneck

MENGAPA LOLOS DETEKSI

- Slow query log hanya menandai query dengan durasi > threshold (mis. 1s)
- Query N+1 masing-masing <1ms, kecil di atas kertas
- Akumulasi N query kecil menghasilkan total latency besar — invisible dalam log

CONTOH PUKUL KETIKA PRODUKSI

- Development: 3 author, 4 query → <5ms
- Production: 500 author, 501 query → 2.4s
- Slow query log melaporkan 0 query lambat — semuanya cepat

DETEKSI YANG BENAR

- Query count profiling, bukan hanya durasi individual
- ORM-level query logger (mis. Django nplusone)
- Instrumentation APM yang mengobservasi pola query

Fast individual queries can mask slow aggregate performance.

Mengapa N+1 Lolos ke Produksi

Tiga faktor struktural: data uji kecil, optimisasi prematur, profiling kurang

FAKTOR 1: DATA UJI KECIL

- Lab & staging memakai data sample 3-5 record
- 4 query terlihat cepat — tidak ada bottleneck yang terlihat
- Prinsip 'works on my machine' menyebabkan kegagalan skalasi

FAKTOR 2: ORM DEFAULT LAZY

- Django: lazy loading default untuk relasi
- Rails: lazy loading default untuk association
- EF Core: lazy loading proxy (opsional tapi sering diaktifkan)

FAKTOR 3: PROFILING TIDAK STANDAR

- Query count tidak diukur sebagai metrik CI/CD
- Fokus pada duration, bukan volume per request
- Tidak ada test assertion untuk jumlah query

Small test data hides linear degradation — profile volume, not just speed.

Arsitektur Lab 22: Tiga Layer

Pisahan Store (mock DB), Repository (data access), Demo (CLI runner)

LAYER STRUKTUR

- Store: Internal/blog/store.go — mock database + query counter
- Repository: internal/blog/repository.go — dua strategi (naive vs eager)
- Demo: cmd/demo/main.go — CLI runner yang mencetak statistik query

THREAD SAFETY

- Store menggunakan sync.Mutex untuk query counter
- Query count increment thread-safe — valid untuk concurrent test
- Race detector lolos tanpa data race (go test -race)

VERIFIKASI KWANTITATIF

- Query counter bukan estimasi — angka pasti
- Test assertion: N+1=4 query, Eager=2 query (hard-coded)
- Deep equality check: reflect.DeepEqual(eager, nplus1)

Make query counts measurable so assertions are exact, not estimated.

Implementasi Naif: Lazy Loading per Item

GetPostsByAuthorID dipanggil di dalam loop — masing-masing menghasilkan satu query

REPOSITORY N+1

- authors := r.store.GetAllAuthors() // Query #1
- for _, author := range authors {
- posts := r.store.GetPostsByAuthorID(author.ID) // Query #2,#3,#4
- result = append(result, AuthorWithPosts{...})
- }

STORE QUERY COUNT

- GetAllAuthors(): queryCount++ → 1
- GetPostsByAuthorID(id): queryCount++ per panggilan
- 3 author → 3 pemanggilan → 3 query tambahan
- Total akumulasi: 4

KARAKTERISTIK

- Intuisi kode natural / readable — ini yang membuatnya sulit diketahui
- Mirip dengan ORM lazy loading default
- Sering ditulis oleh developer junior yang belum sadar

Lazy loading in a loop multiplies query count — batch before iterating.

Solusi Eager Loading: Batch & Memory Map

Kumpulkan semua ID, satu query IN(...), kelompokkan di memori

REPOSITORY EAGER

- authors := r.store.GetAllAuthors() // Query #1
- ids := extractAuthorIDs(authors) // slice [1,2,3]
- allPosts := r.store.GetPostsByAuthorIDs(ids) // Query #2 batch
- groupByAuthor(allPosts) → map[int][]Post
- Build final result from map

STORE BATCH METHOD

- GetPostsByAuthorIDs(authorIDs []int):
- idMap := make(map[int]bool)
- for _, id := range authorIDs { idMap[id] = true }
- return posts where idMap[post.AuthorID]
- queryCount++ once — satu query untuk semua

HASIL

- Total query: 2 (1 untuk author + 1 untuk batch post)
- Terlepas dari berapa banyak author — selalu 2 query
- Data hasil identik dengan N+1 (verified via DeepEqual)

Collect all IDs, fetch in one IN(...) batch, join in memory — O(1) queries.

Eksekusi Demo: Bukti Kuantitatif

Output CLI: query count dan jumlah record yang dimuat

DEMO OUTPUT — N+1

- --- Simulating N+1 Query Problem ---
- Loaded 3 authors with their posts.
- Total queries executed: 4 (1 for authors + 3 for posts)

DEMO OUTPUT — EAGER

- --- Simulating Eager Loading (Batching) ---
- Loaded 3 authors with their posts.
- Total queries executed: 2 (1 for authors + 1 batched query)

INTERPRETASI

- N+1: query count = N+1 (bergantung pada jumlah record)
- Eager: query count = 2 (konstan, tidak bergantung pada N)
- Pada N=1000: N+1=1001 query vs Eager=2 query — perbedaan 999 query

Constant 2 queries beats N+1, and the gap widens linearly with N.

Unit Test: Assert Kuantitatif Query Count

Deep equality & query assertion mencegah regresi secara otomatis

TEST RESULTS

- === RUN TestGetAuthorsWithPostsNPlusOne
- --- PASS: TestGetAuthorsWithPostsNPlusOne (0.00s)
- === RUN TestGetAuthorsWithPostsEager
- --- PASS: TestGetAuthorsWithPostsEager (0.00s)
- === RUN TestEmptyStore
- --- PASS: TestEmptyStore (0.00s)
- PASS — 4/4 test cases pass

ASSERTI QUERY COUNT

- N+1: queryCount == 4 (1 + N, di mana N=3)
- Eager: queryCount == 2 (1 + 1 batch)
- Assertion hard-coded: tidak estimasi — angka pasti

DEEP EQUALITY

- reflect.DeepEqual(eagerResult, nPlusOneResult) → true
- Batching tidak mengubah semantik data — hanya mengurangi I/O
- Race detector: go test -race — lulus tanpa data race

Assert exact query counts in unit tests to prevent N+1 regressions.

Kompleksitas: O(N) → O(1) Query Count

Grafik query count vs jumlah record: linear vs konstan

GRAFIK KOMPLEKSITAS

- N=3: N+1=4 query | Eager=2 query
- N=100: N+1=101 query | Eager=2 query
- N=1K: N+1=1001 query| Eager=2 query
- N=10K: N+1=10001 query| Eager=2 query

ANALISIS O-NOTASI

- N+1: Jumlah query = O(N) relatif terhadap jumlah record
- Eager: Jumlah query = O(1) — konstan, tidak bergantung pada N
- Memory: O(N) keduanya — sama, hanya query saja yang berbeda

FACTOR KONSTAN

- Eager memiliki overhead memory untuk map building
- Tetapi menghemat ribuan round-trip jaringan DB
- Nilai tukar: memory vs latency — biasanya latency lebih mahal

Query count complexity drops from O(N) to O(1) — the gap widens linearly.

N+1 di Luar Database: API & GraphQL Resolvers

Pola yang sama muncul pada HTTP calls dan GraphQL field resolvers

GRAPHQL N+1

- Resolver untuk posts(author) dipanggil per author
- Setiap resolver = 1 HTTP request ke backend
- Solusi standar: DataLoader (Facebook) — batch & cache

HTTP MICROSERVICE N+1

- Endpoint mengembalikan 100 order, lalu fetch item per order
- 100 HTTP request seril, latensi menumpuk
- Solusi: batch endpoint /items?order_id=1,2,3,... atau aggregation service

POLA YANG SAMA

- Database: ORM lazy loading
- HTTP: per-object request di dalam loop
- GraphQL: per-field resolver di dalam list
- Akar masalah: eksekusi I/O berulang di dalam iterasi

N+1 is a pattern, not a layer — it happens wherever I/O runs inside a loop.

DataLoader: Request De-duplication & Batching

Pola batching di level aplikasi untuk GraphQL dan HTTP

DATA LOADER (GRAPHQL)

- Collect requests selama satu tick event loop
- Batch semua request dengan key yang sama ke satu backend call
- Cache hasil per key — request berulang tidak menghitung lagi

HTTP BATCHING EQUIVALENT

- Aggregate IDs, kirim satu request batch ke backend
- Gunakan cache layer (Redis) untuk hasil yang relatif statis
- Pattern ini sama dengan database batch query — konsep universal

KONEKSI KE LAB

- Lab ini: database-level batch via GetPostsByAuthorIDs
- DataLoader: application-level batch via IN(...) equivalent
- Kedua pola: kumpulkan, batch, satukan di memori

Batch and cache: collect requests across a tick, fire one call, cache per key.

Bahaya Mapping-Level Eager Loading

FetchType.EAGER dan semacamnya memuat semua relasi — memory bloat

MASALAH

- JPA FetchType.EAGER: memuat semua relasi otomatis di setiap query
- Tidak ada kontrol selektif — over-fetching terjadi
- Memory bloat: entitas tidak relevan ikut ter-load

PERBEDAAN KRITIS

- Mapping-level: deklaratif di class — selalu eager
- Query-level: eksplisit per query — kontrol penuh
- Lab ini mendemonstrasikan query-level — solusi yang benar

CONTOH JPA

- Entity Author dengan @OneToMany EAGER
- Setiap kali query Author, semua Post ikut ter-load
- Bayangkan: 100 author, masing-masing 1000 post = 100K post loaded

Eager at the mapping level loads everything everywhere — control loading per query.

Trade-off: Cartesian Product Explosion

Eager loading via JOIN menyebabkan hasil dikali jumlah child records

PHENOMENA

- Parent (1) JOIN Child (N) → hasil = 1 x N rows
- Untuk 1 author dengan 50 post → 50 rows yang sama untuk author
- Dengan multiple one-to-many → cartesian explosion paralel

IMPACT

- Network bandwidth: data yang dikirim jauh lebih besar
- Memory: result set di aplikasi jauh lebih besar
- CPU: parsing dan mapping hasil yang lebih lambat

SOLUSI ORM

- Django: prefetch_related() — gunakan query terpisah, join di Python
- EF Core: split query — eksekusi query terpisah per relasi
- SQLAlchemy: selectinload() — batch select, join di memori

JOIN-based eager loading causes cartesian explosion — prefer split/batch queries.

Strategi Alternatif: Column Selection

select/pluck/values/withCount — ambil skalar, bukan entitas penuh

PERBANDINGAN

- Eager loading penuh: SELECT * FROM posts WHERE ... + mapping
- Column selection: SELECT title FROM posts WHERE ... + raw values
- Jika hanya butuh judul atau counter — column selection jauh lebih efisien

API DI BEREBERAPA ORM

- Django: values('title'), withCount('posts')
- Rails: pluck(:title), posts.count
- Laravel: select('title')->withCount('posts')
- EF Core: Select(p => p.Title), ToQueryString

MANFAAT

- Bandwidth: jauh lebih sedikit data dikirim
- Memory: tidak perlu materialisasi entitas penuh
- CPU: parsing lebih cepat — tidak perlu mapper ORM

For scalars and counts, column selection beats eager loading of full entities.

Workflow Profiling-First

Langkah demi langkah: ukur → identifikasi → optimasi

TIGA LANGKAH

- 1. Ukur query count per request (bukan hanya durasi)
- 2. Identifikasi pola N+1 (lazy loading di loop, per-object API call)
- 3. Optimasi: batch eager loading, column selection, atau caching

TOOLING

- Django: django-nplusone, django-debug-toolbar
- Rails: bullet gem
- Laravel: beyondcode/laravel-query-detector
- EF Core: Microsoft.Extensions.Logging + query tag

CI/CD INTEGRASI

- Query count test assertion di CI pipeline
- Threshold maksimal query per endpoint
- Strict loading mode untuk mencegah lazy loading tak disadari

Measure first, optimize second — query count profiling before duration.

Eager Loading di Berbagai ORM

API naming berbeda, konsep dasar sama

TABEL PERBANDINGAN

- ORM | Method | Type | SQL
- -----------|-------------------------|-------------|----------
- Django | select_related() | JOIN | 1 query
- Django | prefetch_related() | Split | 2 queries
- Rails | includes() | Auto-switch | 1/2
- Laravel | with() | Split | 2 queries
- EF Core | Include() | JOIN | 1 query
- EF Core | ThenInclude() | JOIN | 1 query

KUNCI PERBEDAAN

- select_related: JOIN — risiko cartesian explosion
- prefetch_related: split query — aman dari explosion
- includes: Rails memilih otomatis (smart)

KONEKSI KE LAB

- Lab ini: split query via GetPostsByAuthorIDs
- Mapping ini setara dengan prefetch_related / split query
- Bukan JOIN-based eager loading — menghindari cartesian explosion

ORMs agree on the concept — split/batch to avoid cartesian explosion, JOIN to minimize queries.

Evaluasi: N+1 vs Eager Loading

Perbandingan kuantitatif dan kualitatif

TABEL PERBANDINGAN

- Dimensi | N+1 (Lazy) | Eager (Batch)
- ----------|----------|----------
- Jumlah query | N+1 | 2
- Skalabilitas | Linear (O(N)) | Konstan (O(1))
- Memory overhead | Minimal | Map building
- Risk cartesian | Tidak ada | JOIN = ya (hindar)
- Readability | Intuitive | Perlu pemahaman
- Over-fetching | Hanya per item | Semua per satu

QUERY COUNT SUMMARY

- N=3: N+1=4 | Eager=2
- N=100: N+1=101 | Eager=2
- N=1000: N+1=1001 | Eager=2
- N=10000: N+1=10001 | Eager=2

REKOMENDASI

- Gunakan eager loading untuk data yang pasti dibutuhkan
- Gunakan column selection untuk skalar/count
- Gunakan lazy loading hanya untuk data opsional/relasional

Trade intuition for correctness — eager batch wins on query count and stays O(1).

Studi Kasus: GET /api/work-orders

Dari 6 query di dev menjadi 101 di prod — kisah nyata N+1

SCENARIO AWAL

- Endpoint: GET /api/work-orders
- Data uji dev: 5 work order, 1 item each = 6 query
- Response time: <10ms — terlihat cepat
- Lolos deployment ke production

SCENARIO PRODUKSI

- Production: 100 work order, 5 item each
- N+1: 1 + 100 = 101 query seril
- Response time: 2.4 detik (ilustratif)
- Connection pool exhausted — request pending

MITIGASI

- Batched query: WHERE work_order_id IN (...) → 2 query
- Column selection: hanya ambil kolom yang perlu
- Pagination: tidak load 100 work order sekaligus
- Query count assertion di test — mencegah regresi

Dev data hides prod pain — assert query counts for every realistic data size.

Checklist Audit Performa Data Access

9 poin verifikasi sebelum deploy ke production

CHECKLIST

- [ ] Profiling query count sebelum deploy
- [ ] Audit lazy loading dalam loop — ganti ke batch/eager
- [ ] Eager loading per-query, bukan per-mapping (hindari EAGER global)
- [ ] Cek cartesian explosion pada relasi one-to-many/many-to-many
- [ ] Gunakan column selection (pluck/values) untuk skalar
- [ ] Pagination untuk hasil besar
- [ ] Query count assertion di unit/integration test
- [ ] Pertimbangkan strict loading mode
- [ ] Query count test assertion di CI pipeline

ALAT BANTU

- django-nplusone — deteksi N+1 di Django
- bullet gem — deteksi N+1 di Rails
- laravel-query-detector — deteksi di Laravel
- EF Core logging — tracking query patterns

PRINSIP

- Jika query count meningkat linear dengan N → ada N+1
- Jika query count konstan → batching sudah tepat
- Query count assertion = automated guardrail

Nine checkpoints cover detection, batching, and prevention — assert query counts in CI.

Batasan Implementasi Lab 22

Lab ini adalah simulasi konseptual — bukan produksi database asli

BATAS 1: IN-MEMORY MOCK STORE

- Store menggunakan slice in-memory, bukan database nyata
- Query counter hanya counter — tidak ada latency jaringan nyata
- Angka 4 query vs 2 query adalah verifikasi logik, bukan benchmark

BATAS 2: KONEKSI KE ORM

- Lab implementasi manual, bukan integrasi dengan Django/Rails/EF Core
- API batch (GetPostsByAuthorIDs) merepresentasikan konsep IN(...)
- ORM-level lazy vs eager loading tidak langsung ditunjukkan di sini

BATAS 3: ANGKA ILUSTRATIF

- Angka 2.4s pada studi kasus adalah angka ilustratif
- Dataset hanya 3 author — produksi bisa ribuan
- Lab membuktikan konsep query count, bukan performa absolut

This lab proves query-count reduction conceptually — real-world latency varies.

Prinsip Desain Akses Data yang Benar

Tiga prinsip dasar mencegah N+1 secara sistematis

PRINSIP 1: PROFILING- FIRST

- Hitung query count sebelum optimasi
- Tooling: ORM query logger, APM, slow query analysis
- CI/CD: query count threshold assertion

PRINSIP 2: BATCH, JANGAN LOOP

- Kumpulkan ID → satu query IN(...) → join di memori
- Pola ini universal: database, HTTP, GraphQL
- Query-level eager loading — kontrol per query

PRINSIP 3: PILIH KOLOM YANG DIPERLUKAN

- select/pluck/values/withCount — ambil skalar
- Hindari materialisasi entitas penuh jika tidak dipakai
- Reduksi bandwidth, memory, dan CPU parsing

Three principles: measure first, batch not loop, select only what you need.

SOFTWARE ENGINEERING LAB | LAB 22 RINGKASAN

Ringkasan Lab 22

KEY RESULTS

- N+1: 1 + N query (linear dengan record count)
- Eager: 2 query (konstan, terlepas dari N)
- Test assertion: query count verified, deep equality confirmed

MENTAL MODEL

- N+1 is a pattern, not a layer — it strikes wherever I/O runs in a loop.
- Batch all related identifiers into a single IN(...) query.
- Assert query counts in unit tests — guardrails don't regress silently.

RESOURCES

- Repository: https://github.com/lukman-ss/software-engineering-lab/tree/main/labs/22-n-plus-one-query-problem
- Commit SHA: 6649acb946725e993e78f99ec47833a5498cc870
- Run demo: go run ./cmd/demo
- Run tests: go test -v -race ./...

N+1 is a pattern, not a layer — batch all IDs into ONE query, assert count in tests.